

**UNIVERSIDAD MAYOR, REAL Y PONTIFICIA DE
SAN FRANCISCO XAVIER DE CHUQUISACA
FACULTAD DE CIENCIAS Y TECNOLOGIA
CARRERA DE CIENCIAS DE LA COMPUTACIÓN**



Laboratorio 3

Universitario: Pedro Jhoel Antonio Magne Ordoñez

Carrera: Ciencias de la Computación

Materia: SIS421

Grupo: N°1

SUCRE – BOLIVIA

1. Introducción

En este trabajo se desarrollaron dos modelos de redes neuronales recurrentes, LSTM y GRU, utilizando un conjunto de datos meteorológicos con registros tomados cada 10 minutos.

El objetivo fue utilizar la información de las últimas 24 horas para clasificar la siguiente condición meteorológica en tres categorías: Frío, Moderado y Cálido.

Además de comparar el rendimiento de LSTM y GRU, se aplicaron técnicas de optimización y regularización para obtener un entrenamiento más estable y reducir el sobreajuste.

2. Dataset utilizado

Para el proyecto se utilizó el dataset Jena Climate, que contiene mediciones meteorológicas registradas durante varios años. El conjunto original contiene 420.551 registros y 15 columnas.

Se utilizaron las siguientes características:

- Presión atmosférica.
- Temperatura.
- Temperatura de rocío.
- Humedad relativa.
- Velocidad del viento.
- Velocidad máxima del viento.
- Dirección del viento.

Después de la limpieza quedaron 420.531 registros, sin valores nulos.

3. Preparación de los datos

Los datos fueron divididos respetando el orden temporal:

- 70 %: entrenamiento.
- 15 %: validación.
- 15 %: prueba.

Las características fueron normalizadas utilizando StandardScaler, ajustándolo solamente con los datos de entrenamiento.

Para que los modelos pudieran trabajar con la información temporal, se construyeron secuencias de 144 observaciones, correspondientes a 24 horas, ya que existen seis mediciones por hora.

La variable objetivo se dividió en tres categorías:

- 0 – Frío
- 1 – Moderado
- 2 – Cálido

Los límites de las categorías fueron calculados mediante terciles utilizando únicamente el conjunto de entrenamiento.

4. Modelos utilizados

Se implementaron dos modelos:

LSTM

El modelo LSTM utilizó:

- 2 capas recurrentes.
- 64 unidades ocultas.
- Dropout de 0.3.
- 3 clases de salida.

GRU

El modelo GRU utilizó la misma configuración, cambiando únicamente la unidad recurrente de LSTM a GRU.

Esto permitió comparar ambas arquitecturas bajo condiciones similares.

5. Técnicas de optimización y regularización

Para el entrenamiento se utilizaron las siguientes técnicas:

- **Adam:** optimizador utilizado para actualizar los pesos.
- **Learning Rate Scheduler:** redujo automáticamente la tasa de aprendizaje cuando la validación dejó de mejorar.
- **Dropout:** utilizado para reducir el sobreajuste.
- **Weight Decay:** utilizado como regularización L2.
- **Gradient Clipping:** limitó los gradientes para mejorar la estabilidad.
- **Early Stopping:** detuvo el entrenamiento cuando dejó de observarse una mejora suficiente.

La función de pérdida utilizada fue Cross Entropy Loss.

6. Resultados

6.1 LSTM


El modelo LSTM obtuvo los siguientes resultados sobre el conjunto de prueba:

Métrica	Resultado
Accuracy	98.89 %
Precision	98.89 %
Recall	98.89 %
F1-score	98.89 %

La matriz de confusión obtenida fue:

Real / Predicción	Frío	Moderado	Cálido
Frío	20.438	230	0
Moderado	190	22.150	177
Cálido	0	99	19.652

La mayor cantidad de predicciones se encuentra en la diagonal principal, indicando que el modelo clasificó correctamente la mayoría de las muestras.



6.2 GRU


El modelo GRU obtuvo:

Métrica	Resultado
Accuracy	98.94 %
Precision	98.94 %
Recall	98.94 %
F1-score	98.94 %

Su matriz de confusión fue:

Real / Predicción	Frío	Moderado	Cálido
Frío	20.508	160	0
Moderado	235	22.163	119
Cálido	0	155	19.596

Al igual que LSTM, la mayoría de las predicciones se encuentran en la diagonal principal.



7. Comparación

Los resultados finales fueron:

Modelo	Accuracy	Precision	Recall	F1-score
LSTM	98.89 %	98.89 %	98.89 %	98.89 %
GRU	98.94 %	98.94 %	98.94 %	98.94 %

En los resultados, GRU obtuvo un rendimiento ligeramente superior a LSTM, aunque la diferencia fue muy pequeña, aproximadamente 0.05 puntos porcentuales.

Por lo tanto, los dos modelos tuvieron un comportamiento bastante similar y fueron capaces de aprender correctamente los patrones temporales presentes en los datos.

8. Análisis de la matriz de confusión

Al observar las matrices de confusión, se puede notar que los errores se concentran principalmente entre las clases Frío y Moderado, y Moderado y Cálido.

No se presentaron confusiones directas entre Frío y Cálido en ninguno de los dos modelos.

Esto es lógico porque las clases representan niveles consecutivos de temperatura. Una observación cercana al límite entre dos categorías puede ser más difícil de clasificar correctamente.

La clase Moderado concentra buena parte de las confusiones porque se encuentra entre las otras dos categorías.

9. Conclusiones

Después de realizar el experimento, pude comprobar que tanto LSTM como GRU funcionan correctamente para trabajar con datos meteorológicos secuenciales.

El modelo LSTM obtuvo un 98.89 % de Accuracy, mientras que GRU alcanzó un 98.94 %, por lo que GRU tuvo el mejor resultado en esta prueba.

Sin embargo, la diferencia entre ambos modelos fue muy pequeña, por lo que considero que los dos modelos tuvieron un resultado excelente.

También pude observar que las técnicas utilizadas durante el entrenamiento, como Dropout, Weight Decay, Learning Rate Scheduler y Early Stopping, permitieron controlar el proceso de aprendizaje y evitar continuar entrenando cuando el modelo ya no presentaba mejoras importantes.

Finalmente, las matrices de confusión permitieron comprobar visualmente que la mayoría de las predicciones fueron correctas y que los errores se produjeron principalmente entre clases consecutivas.